CQA Evidence

Оценка диалогов
с проверяемыми основаниями

THE BOYS

Kuzhagaliev Nurali and Kilybayeva Nuraiym

Восемь критериев качества диалога

Критерий	Вес	Шкала
Установление контакта	10	Да / Нет
Выявление потребности	15	Да / Нет / N/A
Идентификация	20	Да / Нет / N/A
Корректная и полная консультация	20	0 / 5 / 10 / 15 / 20 / N/A
Эмпатия и клиентоориентированность	15	Да / Нет
Управление диалогом	15	0 / 4 / 7 / 10
Завершение	5	Да / Нет / N/A
Грубые ошибки	Отдельный флаг	Да / Нет

Чаты и транскрипты на русском, казахском и английском

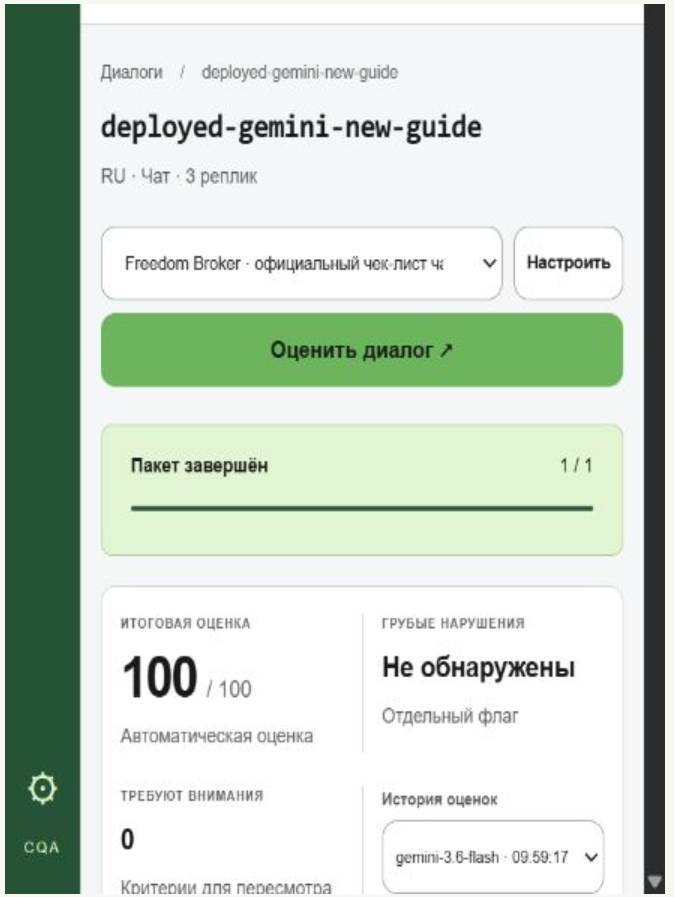
Основание каждого ответа

Реплика оператора №2

«Здравствуйте! Меня зовут Лаура.»

Установление контакта: ДА

Код проверяет точный текст цитаты и роль автора исходной реплики.



Реальный запрос в онлайн-демо

Модель, проверка и расчёт

01 **Ответ модели**

Ступень шкалы, основание, ссылки на реплики и ограничения вывода

02 **Проверка источника**

ID, точные цитаты, роли авторов и покрытие нужного участка

03 **Детерминированный итог**

Веса, перераспределение N/A и единое округление до сотых

Недопустимый ответ API сохраняется как ошибка анализа

Инструменты пересмотра решения

Приоритет проверки

Карта показывает, насколько ответ по критерию влияет на общий балл.

Независимая повторная оценка

Повторный запрос получает исходный диалог без первого ответа модели.

Апелляция с историей

Решение проверяющего сохраняется отдельно от исходной оценки AI.



Результаты проверок

Проверка	Объём	Наблюдение
Собственные сценарии v3	40 примеров	Для всех есть допустимый результат[1]
Отложенная авторская проверка	20 примеров	21/21 выбранных целевых ответов
Изменения текста v4	6 примеров	12/12 выбранных целевых ответов
Размещённое демо	2 новых примера	6/6 выбранных целевых ответов
Контрольный FBroker (PROD)	**10 чатов**	**10 ok, 0 error. Результаты в GitHub**

171 автоматический тест

4 конфигурации CI

Авторские ответы не являются независимой экспертной разметкой.

[1] Сценарии v3 обработаны в прогонах разных версий и провайдеров.

Рабочая архитектура

Браузер

Новый диалог, рубрика, цитаты, апелляция и выгрузка результата

Python и SQLite

Версии данных, расчёт балла, история решений и план пакета

Gemini и Groq

Облачные API на бесплатных тарифах. Фактическую модель сохраняем в аудите.

Render

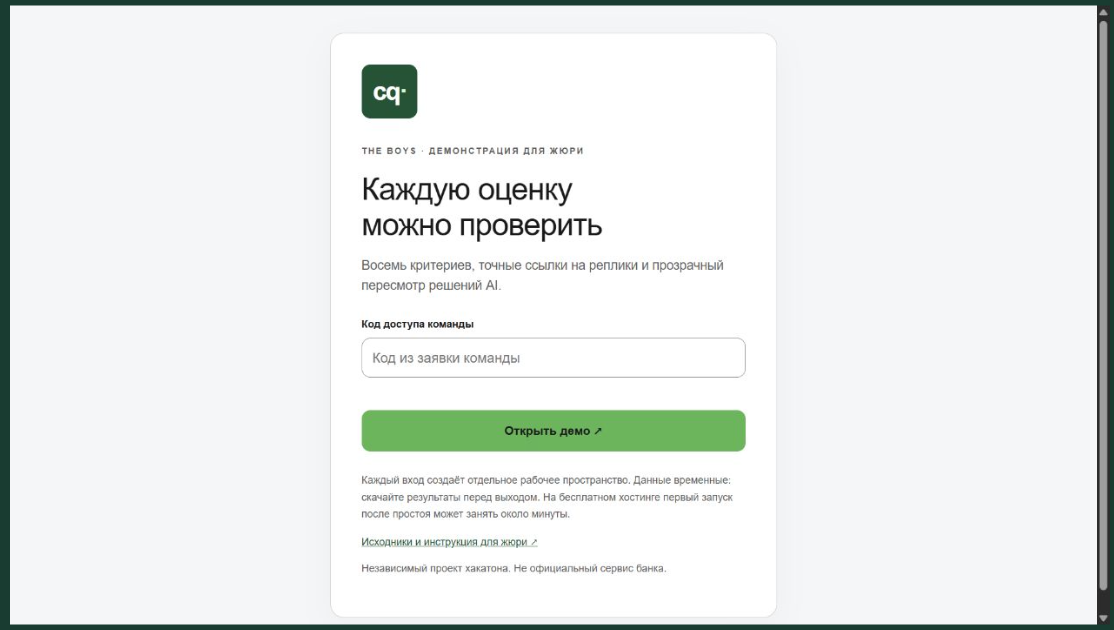
Код входа, отдельный сеанс для жюри и ключи в серверных переменных

Проверка на новом диалоге

1. Загрузить транскрипт

2. Оценить по рубрике

3. Открыть цитату и пересмотр



Открыть онлайн-демо

cqa-evidence-the-boys.onrender.com

Код доступа передаём отдельно. Render Free может просыпаться около минуты.
Лимит демо: 200 диалогов в сутки. Дополнительно действуют квоты API.

Пример перерасчёта при N/A

Общий вопрос без проверки личности

Выявление потребности: N/A, вес 15
Идентификация: N/A, вес 20
Сумма применимых весов: 65

При потере 10 баллов за контакт

55 / 65 × 100 = 84,62

Грубая ошибка остаётся отдельным флагом

Результаты контрольного прогона

DEV: 65 результатов

65 ok, 0 error по формату выгрузки

В 55 исторических аудитах ответа «грубых ошибок нет» покрытие исходника неполное.
Эти основания требуют перепроверки.

PROD: 10 контрольных чатов

10 ok, 0 error. Commit и push выполнены

80 решений по критериям.
129 ссылок на реплики проверены.
Получение и push: около 5 минут.

Результаты PROD в GitHub

Независимой экспертной разметки нет.
Официальную точность на PROD пока не измеряли.